

LAPORAN UJIAN AKHIR SEMESTER

PEMBELAJARAN MESIN

Prediksi Kelayakan Peminjaman Kredit Nasabah Menggunakan Machine Learning

(Studi Kasus: German Credit Data with Credit Risk)



Disusun Oleh :

IZZA ADITYA SATRIA W

A11.2024.15994

A11.4404

UNIVERSITAS DIAN NUSWANTORO

FAKULTAS ILMU KOMPUTER

PROGRAM STUDI TEKNIK INFORMATIKA

2026

DAFTAR ISI

BAB 1 PENDAHULUAN	4
1.1 Latar Belakang Masalah.....	4
1.2 Problem Statement.....	4
1.3 Tujuan Bisnis.....	5
1.4 Metrik Kesuksesan Project	5
1.5 Sumber Dataset & Statistik Deskriptif Awal	5
1.6 Ringkasan Kolom	6
BAB II Exploratory Data Analysis & Preprocessing.....	7
2.1 Analisis Kualitas.....	7
2.1.1 Data Duplikat.....	7
2.1.2 Missing Value	7
2.1.3 Outlier (Metode IQR)	7
2.1.4 Inkonsistensi Data	8
2.2 Analisis Univariat	9
2.2.1 Distribusi Target (Credit Risk).....	9
2.2.2 Distribusi Fitur Numerik.....	9
2.3 Analisis Multivariat	10
2.3.1 Fitur Numerik vs Target	10
2.3.2 Fitur Kategorikal vs Target.....	10
2.3.3 Korelasi Antar Fitur Numerik	11
2.3.4 Duration vs Credit Amount (diwarnai Credit Risk).....	12
2.4 Feature Engineering dan Preprocessing	12
2.5 Pembagian Dataset.....	13
BAB III MODELING DAN EVALUATION	14
3.1 Algoritma yang Digunakan	14
3.2 Hyperparameter Tuning	14
3.3 Hasil Evaluasi dan Perbandingan Model.....	14
3.4 Interpretasi Model (Feature Importance).....	16
3.5 Pemilihan Model Terbaik dan Justifikasi	17
BAB IV DEPLOYMENT DAN APLIKASI STREAMLIT	18
4.1 Arsitektur Aplikasi.....	18
4.2 Fitur Utama Aplikasi.....	18
4.2.1 User Interface.....	19
4.3 Validasi Input	19
4.4 Cara Menjalankan Aplikasi	20
BAB V STRUKTUR REPOSITORY DAN DOKUMENTASI.....	21

5.1 Deskripsi DATASET	21
- SC App.py :	21
- Link Deployment apk Streamlit : https://pm-4404-79qbb6hpg7qfiprh7kj7mk.streamlit.app/	21
- Link Youtube : https://youtu.be/9FjTqHnijM0?si=ToEy9vozztqunUvq	21
- Link Repo GITHUB : https://github.com/izza1234567859/PM-4404.git	21
BAB VI KESIMPULAN DAN REKOMENDASI	22
6.1 Kesimpulan	22
6.2 Rekomendasi	22
REFERENSI	23

BAB 1 PENDAHULUAN

1.1 Latar Belakang Masalah

Pemberian kredit merupakan salah satu layanan utama pada sektor perbankan dan lembaga keuangan. Dalam proses pengajuan kredit, pihak bank harus melakukan analisis terhadap kondisi finansial dan karakteristik calon nasabah untuk menentukan apakah pengajuan kredit dapat diterima atau ditolak. Kesalahan dalam pengambilan keputusan kredit dapat menyebabkan risiko kerugian, seperti meningkatnya jumlah kredit macet akibat nasabah yang tidak mampu melakukan pembayaran.

Pada proses konvensional, analisis kelayakan kredit sering dilakukan secara manual berdasarkan pemeriksaan dokumen dan penilaian petugas kredit. Cara tersebut membutuhkan waktu yang cukup lama dan memiliki kemungkinan terjadinya subjektivitas dalam pengambilan keputusan. Oleh karena itu, diperlukan sebuah sistem berbasis machine learning yang dapat membantu melakukan prediksi kelayakan kredit secara lebih cepat dan konsisten berdasarkan pola data historis.

Seiring meningkatnya jumlah nasabah dan kompleksitas data, diperlukan suatu pendekatan yang lebih objektif, cepat, dan berbasis data. Pada project ini, machine learning digunakan untuk membangun model klasifikasi yang dapat memprediksi risiko kredit nasabah berdasarkan karakteristik tertentu. Model akan mengklasifikasikan calon nasabah menjadi dua kategori, yaitu layak menerima kredit (Credit Risk = Good) dan tidak layak menerima kredit (Credit Risk = Bad).

1.2 Problem Statement

Untuk mengatasi permasalahan tersebut, machine learning digunakan untuk membangun model prediksi kelayakan kredit berdasarkan pola dari data historis nasabah. Fitur yang digunakan dalam proses prediksi meliputi usia nasabah, jenis kelamin, tingkat keahlian pekerjaan (job skill level), status tempat tinggal, kondisi rekening tabungan, kondisi rekening giro, jumlah kredit yang diajukan, durasi kredit, serta tujuan pengajuan kredit. Data tersebut diproses melalui tahap preprocessing seperti penanganan missing value, encoding data kategorikal, dan penskalaan (scaling) data numerik sebelum masuk ke tahap training model.

Project ini menggunakan German Credit Data with Credit Risk yang memuat profil 954 nasabah beserta atribut demografis dan finansialnya, serta label risiko kredit (Credit Risk). Dataset ini digunakan untuk membangun model klasifikasi biner menggunakan algoritma Logistic Regression, Random Forest, dan XGBoost, yang kemudian dibandingkan performanya untuk memilih model terbaik.

Tujuan akhir proyek ini adalah menghasilkan sistem prediksi kelayakan kredit yang dapat membantu proses pengambilan keputusan kredit secara lebih cepat, objektif, dan berbasis data, sebagai alat bantu (decision support tool) bagi analis kredit bukan pengganti sepenuhnya penilaian manusia untuk kasus-kasus tepi (edge case).

1.3 Tujuan Bisnis

Project ini bertujuan membangun model machine learning klasifikasi biner yang dapat memprediksi apakah seorang calon nasabah termasuk kategori kredit baik (good risk) atau kredit buruk (bad risk) berdasarkan atribut demografis dan finansial yang tersedia saat pengajuan (usia, pekerjaan, status tempat tinggal, saldo tabungan/rekening giro, jumlah kredit, durasi pinjaman, dan tujuan kredit). Dengan model ini, proses credit scoring dapat dilakukan lebih cepat, konsisten, dan berbasis data membantu analis kredit sebagai decision support tool, bukan menggantikan sepenuhnya keputusan manusia untuk kasus yang bersifat edge-case.

1.4 Metrik Kesuksesan Project

Kesalahan klasifikasi pada kasus ini memiliki bobot kerugian yang tidak simetris menyetujui kredit nasabah yang sebenarnya bad risk (False Negative) jauh lebih mahal bagi bank dibanding menolak nasabah yang sebenarnya good risk (False Positive). Oleh karena itu, metrik kesuksesan yang digunakan bukan hanya Accuracy, melainkan:

- Recall kelas Bad : mengukur seberapa besar model mampu menangkap nasabah berisiko, agar potensi kerugian akibat gagal bayar diminimalkan.
- ROC-AUC : mengukur kemampuan model membedakan kelas good vs bad secara keseluruhan, robust terhadap distribusi kelas yang tidak seimbang.
- Precision & F1-Score kelas Bad : memastikan model tidak terlalu agresif menolak nasabah baik, sehingga potensi bisnis bank tetap sehat.

Target proyek: mencapai $\text{ROC-AUC} \geq 0.75$ dan $\text{Recall kelas Bad} \geq 0.65$ pada test set, sebagai baseline layak-pakai untuk proof-of-concept sistem credit scoring berbasis machine learning.

1.5 Sumber Dataset & Statistik Deskriptif Awal

Dataset yang digunakan adalah German Credit Data, dataset publik klasik untuk studi credit risk, yang aslinya disusun oleh Prof. Dr. Hans Hofmann (1994) dan dipublikasikan di UCI Machine Learning Repository. Dataset ini kemudian diproses ulang (kolom disederhanakan menjadi format yang lebih mudah dibaca) dan didistribusikan melalui Kaggle.

Dokumentasi & Tautan Sumber

Versi dengan kolom Credit Risk terintegrasi (dipakai pada project ini)

- dataset <https://www.kaggle.com/datasets/benjaminmcgregor/german-credit-data-set-with-credit-risk>
- Dataset ini merupakan pengembangan dari **German Credit Dataset** yang berasal dari UCI Machine Learning Repository. Dataset berisi data historis nasabah kredit beserta label risiko kredit yang digunakan sebagai target klasifikasi.

1.6 Ringkasan Kolom

Berikut ringkasan struktur dataset sebelum tahap preprocessing:

Atribut	Nilai
Jumlah baris (nasabah)	954
Jumlah kolom	11 (10 fitur + 1 kolom index)
Fitur numerik	Age, Job (kode ordinal), Credit amount, Duration
Fitur kategorikal	Sex, Housing, Saving accounts, Checking account, Purpose
Target	Credit Risk (1 = Good/layak, 2 = Bad/tidak layak)
Distribusi target	665 Good (69.7%) vs 289 Bad (30.3%) — imbalanced
Rentang usia (Age)	19 – tertinggi pada data, rata-rata ≈ 35.5 tahun
Rata-rata jumlah kredit (Credit amount)	$\approx 3,279$ (std $\approx 2,853$), rentang mulai dari 250
Rata-rata durasi kredit (Duration)	≈ 20.8 bulan (std ≈ 12.0)

Kolom	Tipe	Deskripsi
Unnamed: 0	int64	ID/index baris (akan di-drop)
Age	int64	Usia nasabah (19 – 75 tahun)
Sex	object	Jenis kelamin (male/female)
Job	int64	Kode skill kerja (0–3, ordinal)
Housing	object	Status tempat tinggal (own/rent/free)
Saving accounts	object	Saldo tabungan (little/moderate/quite rich/rich)
Checking account	object	Saldo rekening giro (little/moderate/rich)
Credit amount	int64	Jumlah kredit yang diajukan
Duration	int64	Durasi kredit (bulan)
Purpose	object	Tujuan kredit (car, education, radio/TV, dll.)
Credit Risk	int64	Target: 1 = good, 2 = bad

BAB II

Exploratory Data Analysis & Preprocessing

2.1 Analisis Kualitas

2.1.1 Data Duplikat


Pengecekan baris duplikat menggunakan `df.duplicated().sum()` menunjukkan tidak ditemukan satu pun baris duplikat pada dataset ini (0 dari 954 baris). Dengan demikian, tidak diperlukan langkah `drop_duplicates()` pada tahap preprocessing.

Notebook EDA & Processing :

https://drive.google.com/file/d/1l7wXmRzvcgT8gUinxhXO1cMqKPysv_fb/view?usp=drive_link

2.1.2 Missing Value

Pengecekan nilai kosong pada seluruh kolom menunjukkan dua kolom kategorikal memiliki missing value yang cukup signifikan:




Gambar 1. Jumlah missing value per kolom

Pola kekosongan ini bukan missing-at-random biasa. Dalam konteks data kredit, nilai kosong pada Saving accounts dan Checking account kemungkinan besar merepresentasikan nasabah yang memang tidak memiliki rekening tabungan atau rekening giro sama sekali, bukan kesalahan pencatatan. Karena itu, strategi penanganan yang dipilih adalah mengimputasi nilai kosong sebagai kategori baru "none" (bukan modus atau dropna), sehingga informasi "tidak memiliki rekening" tetap dipertahankan sebagai sinyal yang berpotensi prediktif, alih-alih membuang hampir separuh data jika menggunakan `dropna()`.

2.1.3 Outlier (Metode IQR)

Deteksi outlier pada tiga fitur numerik (Age, Credit amount, Duration) dilakukan menggunakan metode Interquartile Range (IQR), dengan batas bawah/atas $Q1 - 1.5 \times IQR$ dan $Q3 + 1.5 \times IQR$:

Fitur	Q1	Q3	IQR	Batas Bawah	Batas Atas	Jml Outlier	% Outlier
Age	27.00	42.00	15.0	4.50	64.50	23	2.41%
Credit amount	1,360.25	3,975.25	2,615.0	-2,562.25	7,897.75	70	7.34%
Duration	12.00	24.00	12.0	-6.00	42.00	66	6.92%



Gambar 2. Boxplot deteksi outlier pada Age, Credit amount, dan Duration

Outlier yang terdeteksi pada ketiga kolom bersifat wajar secara bisnis, misalnya nasabah dengan jumlah kredit besar atau durasi kredit panjang bukan kesalahan input data. Karena algoritma yang digunakan pada tahap modeling (Random Forest, XGBoost) tidak sensitif terhadap outlier, dan Logistic Regression memakai StandardScaler, outlier tidak dihapus atau di-clip, melainkan tetap dipertahankan. Menghapus nilai-nilai ini berisiko membuang nasabah "ekstrem" yang justru penting untuk mempelajari pola risiko kredit tinggi.

2.1.4 Inkonsistensi Data

Pemeriksaan terhadap seluruh kolom kategorikal tidak menemukan inkonsistensi penulisan (typo, kapitalisasi ganda, atau variasi ejaan). Kategori yang teridentifikasi pada masing-masing kolom adalah sebagai berikut:

Kolom	Kategori
Sex	female, male
Housing	free, own, rent
Saving accounts	little, moderate, quite rich, rich (+ missing → "none")
Checking account	little, moderate, rich (+ missing → "none")
Purpose	business, car, domestic appliances, education, furniture/equipment, radio/TV, repairs, vacation/others


Kolom Job berisi kode ordinal tingkat keahlian pekerjaan (0 = unskilled non-resident, 1 = unskilled resident, 2 = skilled, 3 = highly skilled) sehingga tetap diperlakukan sebagai fitur numerik/ordinal. Target Credit Risk bernilai

1 (good/layak) dan 2 (bad/tidak layak), yang selanjutnya di-encode ulang menjadi biner 0/1 agar tidak ambigu pada tahap modeling.

2.2 Analisis Univariat

2.2.1 Distribusi Target (Credit Risk)

- Insight 1 : Data imbalance kelas target tidak seimbang (69.7% good vs 30.3% bad), sehingga evaluasi model wajib memakai Recall/F1/ROC-AUC, bukan hanya Accuracy.




Gambar 3. Distribusi kelas Credit Risk

Distribusi kelas target menunjukkan ketidakseimbangan (class imbalance): 665 nasabah (69.7%) berada pada kelas Good, sedangkan 289 nasabah (30.3%) berada pada kelas Bad. Kondisi ini menjadi pertimbangan penting pada tahap modeling evaluasi model tidak dapat hanya mengandalkan Accuracy, melainkan harus memperhatikan Recall, Precision, F1-Score, dan ROC-AUC pada kelas Bad, serta penggunaan teknik seperti `class_weight='balanced'` saat training.

2.2.2 Distribusi Fitur Numerik

- Insight 2 : Outlier pada Age, Credit amount, dan Duration bersifat wajar secara bisnis (2.4%–7.3% dari data) dan dipertahankan karena algoritma tree-based yang digunakan tidak sensitif terhadapnya.




Gambar 4. Distribusi Age, Credit amount, dan Duration

Age memiliki distribusi condong ke kanan (right-skewed) dengan mayoritas nasabah berusia muda hingga paruh baya (sekitar 20–40 tahun) dan ekor panjang ke usia yang lebih tua. Credit amount juga sangat right-skewed sebagian besar pengajuan kredit bernilai kecil hingga menengah, namun terdapat sejumlah kecil pengajuan dengan nominal sangat besar. Duration terkonsentrasi pada durasi pendek hingga menengah (sekitar 12–24 bulan) dengan beberapa pengajuan berdurasi lebih panjang.

2.3 Analisis Multivariat

2.3.1 Fitur Numerik vs Target

- Insight 3: Nasabah bad risk cenderung mengajukan kredit lebih besar & berdurasi lebih panjang: rata-rata 3.934 & 24.6 bulan (bad) vs 2.994,5 & 19,1 bulan (good).




Gambar 5. Credit amount dan Duration terhadap Credit Risk

Credit Risk	Rata-rata Credit amount	Rata-rata Duration
1 (Good)	2,994.5	19.1 bulan
2 (Bad)	3,934.0	24.6 bulan

Nasabah dengan kredit bad risk cenderung mengajukan jumlah kredit yang lebih besar dan durasi pinjaman yang lebih panjang dibandingkan nasabah good risk. Pola ini konsisten dengan intuisi bisnis: pinjaman bernilai besar dan berjangka panjang membawa risiko gagal bayar yang lebih tinggi.

2.3.2 Fitur Kategorikal vs Target

- Insight 4 : Nasabah dengan kondisi rekening tabungan/giro yang kosong atau bersaldo kecil berasosiasi/ menunjukkan dengan proporsi bad risk yang lebih tinggi, menandakan fitur ini berpotensi prediktif.




Gambar 6. Sex, Housing, Saving accounts, Checking account, dan Purpose terhadap Credit Risk

Beberapa pola menarik teramati dari visualisasi fitur kategorikal terhadap target: nasabah dengan kondisi rekening giro (checking account) berstatus "little" atau kosong ("none") menunjukkan proporsi bad risk yang lebih tinggi dibandingkan nasabah dengan saldo "moderate" atau "rich". Pola serupa terlihat pada Saving accounts nasabah tanpa tabungan atau bersaldo kecil cenderung memiliki risiko kredit yang lebih tinggi. Status tempat tinggal (Housing) "rent" juga cenderung berasosiasi dengan risiko lebih tinggi dibandingkan status "own". Dari sisi Purpose, tujuan kredit tertentu (misalnya kebutuhan bisnis atau peralatan domestik) menunjukkan proporsi bad risk yang relatif berbeda dibandingkan tujuan lain seperti radio/TV.

2.3.3 Korelasi Antar Fitur Numerik

- Insight 5 : Credit amount dan Duration berkorelasi kuat ($r \approx 0.63$), dan keduanya lebih tinggi pada nasabah bad risk (rata-rata kredit 3,934 & durasi 24.6 bulan vs 2,994.5 & 19.1 bulan pada good risk).




Gambar 7. Correlation heatmap Age, Job, Credit amount, Duration

Credit amount dan Duration menunjukkan korelasi positif yang cukup kuat ($r \approx 0.63$) semakin besar nominal kredit yang diajukan, semakin panjang pula tenor pembayarannya, yang masuk akal karena bank umumnya menyesuaikan durasi cicilan dengan besar pinjaman. Korelasi antar fitur numerik lainnya (Age, Job) terhadap Credit amount dan Duration relatif lemah, mengindikasikan bahwa kedua fitur tersebut memberi informasi yang cukup independen bagi model.

2.3.4 Duration vs Credit Amount (diwarnai Credit Risk)

- Insight 6 : Titik bad risk terkonsentrasi pada kredit besar & durasi Panjang, namun tumpang tindih dengan good risk di area menengah



Gambar 8. Scatter plot Duration vs Credit amount, diwarnai berdasarkan Credit Risk

Visualisasi scatter plot mempertegas temuan sebelumnya: titik-titik berlabel bad risk lebih terkonsentrasi pada wilayah kredit besar dan durasi panjang, meskipun sebarannya cukup bertumpang tindih dengan kelas good risk pada wilayah nilai kredit dan durasi menengah. Hal ini mengindikasikan bahwa kombinasi Credit amount dan Duration saja belum cukup untuk memisahkan kelas secara sempurna diperlukan kombinasi dengan fitur lain (rekening tabungan/giro, tujuan kredit, dll.) yang akan ditangkap oleh model machine learning pada tahap selanjutnya.

2.4 Feature Engineering dan Preprocessing

Tiga fitur turunan ditambahkan lewat fungsi deterministik (tidak butuh proses *fit* dari data), sehingga aman diterapkan langsung ke train, validation, maupun test tanpa risiko leakage:

- Feature engineering: penambahan fitur turunan Credit_per_Month (Credit amount / Duration, sebagai proksi beban cicilan bulanan) dan Age_Group (kategori usia: Young, Adult, Middle, Senior), serta pemetaan kode ordinal Job menjadi label Job_Skill.

Karena fungsi `feature_engineering()` bersifat transformasi baris-demi-baris tanpa parameter yang dipelajari dari data (bukan fit-transform seperti scaler/encoder), fungsi ini diterapkan terpisah pada `X_train`, `X_val`, dan `X_test` setelah split tidak ada informasi dari validation/test yang bocor ke training.

Tahap preprocessing dilakukan sebagai berikut:

- Numerik (Age, Job, Credit amount, Duration, Credit_per_Month): imputasi median + StandardScaler.
- Kategorikal umum (Sex, Housing, Purpose, Age_Group, Job_Skill): imputasi modus + OneHotEncoder.
- Kategorikal dengan missing bermakna (Saving accounts, Checking account): imputasi konstanta "none" + OneHotEncoder.

2.5 Pembagian Dataset

Dataset dibagi menjadi train (70%), validation (15%), dan test (15%) secara stratified agar proporsi kelas target tetap terjaga di setiap subset (bad-rate ≈ 0.30 pada train, validation, maupun test). Pembagian dilakukan sebelum proses fitting imputer/scaler/encoder, untuk mencegah data leakage seluruh proses fitting hanya "melihat" data train.

Subset	Jumlah Baris	Bad-rate
Train	667	0.303
Validation	143	0.301
Test	144	0.306

BAB III

MODELING DAN EVALUATION

3.1 Algoritma yang Digunakan

Tiga algoritma klasifikasi diimplementasikan (melebihi syarat minimal 2 model) agar perbandingan lebih kaya dan mewakili spektrum kompleksitas yang berbeda:

1. Logistic Regression, baseline linear, cepat, dan paling mudah diinterpretasi (koefisien berkorespondensi langsung dengan arah pengaruh tiap fitur).
2. Random Forest, ensemble berbasis pohon (bagging) yang mampu menangkap interaksi non-linear antar fitur tanpa perlu asumsi distribusi data.
3. XGBoost, gradient boosting yang secara umum memberi performa terbaik pada data tabular berukuran menengah seperti dataset ini.

Ketiga algoritma dibungkus dalam sklearn Pipeline yang menyatukan preprocessor (ColumnTransformer dari BAB II) dengan classifier, sehingga transformasi data dan training model berjalan sebagai satu kesatuan yang konsisten pada train, validation, maupun test. Untuk mengatasi *class imbalance* (69.7% Good vs 30.3% Bad) yang teridentifikasi pada tahap EDA, setiap model diberi penyesuaian bobot kelas:

- Logistic Regression & Random Forest → `class_weight='balanced'`
- XGBoost → `scale_pos_weight` dihitung dari rasio kelas mayoritas terhadap minoritas pada data train ($\text{bad_ratio} = (\text{y_train}==0).\text{sum}() / (\text{y_train}==1).\text{sum}()$)

Kode Training & Model : https://drive.google.com/file/d/1jAKf32vCbtwkGVsGfFnD5Pvh8SFY2Eo-/view?usp=drive_link

3.2 Hyperparameter Tuning

Tuning dilakukan menggunakan 5-fold Stratified Cross Validation (StratifiedKFold(`n_splits=5`, `shuffle=True`)) dengan skor ROC-AUC sebagai metrik optimasi, karena robust terhadap distribusi kelas yang tidak seimbang. Seluruh proses tuning hanya dijalankan pada data train validation dan test set tidak disentuh sama sekali pada tahap ini.

Teknik tuning dipilih menyesuaikan ukuran ruang parameter masing-masing model:

3.3 Hasil Evaluasi dan Perbandingan Model

Ketiga model hasil tuning (`best_estimators`) dievaluasi pada validation set (143 baris, belum pernah dilihat selama tuning) menggunakan Accuracy, Precision, Recall, F1-Score, dan ROC-AUC seluruhnya difokuskan pada kelas Bad (1) sesuai metrik kesuksesan project.


Model	Accuracy	Precision (Bad)	Recall (Bad)	F1 (Bad)	Bad-rate
Random Forest	0.7692	0.5893	0.7674	0.6667	0.303
XGBoost	0.7552	0.5645	0.8140	0.6667	0.301
Logistic Regression	0.7483	0.5574	0.7907	0.6538	0.306

Beberapa observasi:

- **Random Forest** mencatat ROC-AUC tertinggi (0.8372) dan Accuracy tertinggi, dengan keseimbangan Precision–Recall yang paling baik di antara ketiganya.
- **XGBoost** memiliki Recall (Bad) tertinggi (0.8140) paling agresif menangkap nasabah berisiko namun dengan Precision terendah, artinya lebih banyak nasabah Good yang salah ditolak.
- **Logistic Regression**, sebagai model paling sederhana, tetap kompetitif (ROC-AUC 0.7958) meski tertinggal dari dua model ensemble/boosting.

Confusion matrix dan ROC curve pada validation set memperkuat pola ini: kurva ROC Random Forest dan XGBoost hampir berhimpit dan sama-sama berada jauh di atas garis diagonal (baseline acak), sedangkan Logistic Regression sedikit di bawah keduanya. Classification report memperlihatkan Random Forest mencapai precision 0.89 / recall 0.77 pada kelas Good dan precision 0.59 / recall 0.77 pada kelas Bad trade-off yang paling seimbang mengingat konteks bisnis yang mementingkan Recall Bad tanpa mengorbankan terlalu banyak Precision.

ROC Curve — Model Terbaik



Gambar 9. ROC Curve ketiga model pada Validation Set Random Forest dipilih sebagai model terbaik karena kurva ROC-nya paling mendekati performa ideal (sudut kiri-atas) dengan AUC tertinggi (0.837), didukung oleh keunggulan yang konsisten pada metrik evaluasi lain menjadikannya pilihan paling solid untuk sistem prediksi kelayakan kredit ini.


```
=== Ringkasan Perbandingan Model (Validation Set) ===
      Accuracy Precision (Bad) Recall (Bad) F1 (Bad) ROC-AUC
Model
Random Forest 0.7692      0.5893      0.7674      0.6667      0.8372
XGBoost       0.7552      0.5645      0.8140      0.6667      0.8337
Logistic Regression 0.7483      0.5574      0.7907      0.6538      0.7958

>>> Model terpilih: Random Forest <<<
Alasan: ROC-AUC dan/atau Recall (Bad) tertinggi pada validation set di antara ketiga model.
```

Gambar 10. Ringkasan Perbandingan Model pada Validation Set

Random Forest unggul pada Accuracy (0.7692) dan ROC-AUC (0.8372), sedangkan XGBoost unggul tipis pada Recall (Bad) (0.8140) namun dengan Precision (Bad) yang lebih rendah (0.5645 vs 0.5893). F1-Score (Bad) kedua


model identik (0.6667), sehingga keputusan akhir pemilihan model bergantung pada ROC-AUC sebagai pembeda yang dimenangkan Random Forest.



Gambar 11. Confusion Matrix Random Forest pada Test Set

Dari confusion matrix ini diperoleh Recall (Bad) = $31/44 \approx 0.7045$ dan Precision (Bad) = $31/(31+29) \approx 0.5167$. False negative sebanyak 13 nasabah adalah kasus yang secara bisnis paling berisiko (nasabah sebenarnya Bad tapi disetujui kreditnya), namun proporsinya ($13/44 \approx 29.5\%$) masih dalam batas yang wajar untuk model baseline proof-of-concept, dan berhasil memenuhi target Recall Bad ≥ 0.65

3.4 Interpretasi Model (Feature Importance)



Gambar 12. Chart ini menampilkan 15 fitur (hasil preprocessing, termasuk hasil one-hot encoding) dengan kontribusi terbesar terhadap prediksi model Random Forest, diurutkan dari yang paling berpengaruh.

Model Random Forest secara dominan mengandalkan kondisi rekening (checking/saving account) dan karakteristik finansial pinjaman (jumlah kredit, durasi, beban cicilan bulanan) untuk memprediksi risiko kredit

bukan atribut demografis. Ini konsisten dengan hasil SHAP di bagian berikutnya dan memperkuat validitas model secara bisnis, karena pola yang dipelajari sejalan dengan intuisi analis kredit di dunia nyata.

3.5 Pemilihan Model Terbaik dan Justifikasi

Kriteria pemilihan model terbaik tidak semata-mata Accuracy mengingat kesalahan yang paling mahal secara bisnis adalah *False Negative* (menyetujui kredit nasabah yang sebenarnya Bad risk) melainkan kombinasi ROC-AUC (kemampuan membedakan kelas secara keseluruhan) dan Recall kelas Bad (kemampuan menangkap nasabah berisiko).

```
*** === Evaluasi Akhir di Test Set ===
Accuracy: 0.7083
Precision (Bad): 0.5167
Recall (Bad): 0.7045
F1 (Bad): 0.5962
ROC-AUC: 0.7468

Classification Report - Random Forest (Test Set):
              precision    recall  f1-score   support

   Good(0)       0.85        0.71        0.77        100
   Bad(1)        0.52        0.70        0.60         44

   accuracy                0.71        144
  macro avg              0.68        0.71        0.68        144
 weighted avg              0.74        0.71        0.72        144
```

Gambar 13. Output Evaluasi Akhir Model Random Forest pada Test Set

Dibandingkan target proyek yang ditetapkan di BAB I ($\text{ROC-AUC} \geq 0.75$ dan $\text{Recall Bad} \geq 0.65$), hasil pada test set menunjukkan Recall Bad tercapai ($0.7045 > 0.65$), sementara ROC-AUC (0.7468) sedikit di bawah target 0.75

BAB 1V

DEPLOYMENT DAN APLIKASI STREAMLIT

4.1 Arsitektur Aplikasi

Aplikasi ini dibangun dengan alur end-to-end mulai dari data mentah hingga prediksi interaktif. Data mentah di **data/raw/** terlebih dahulu dieksplorasi pada **01_eda.ipynb**, kemudian diproses dan dimodelkan pada **02_modeling.ipynb**, yang menghasilkan model terbaik beserta pipeline preprocessing-nya yang disimpan masing-masing sebagai **models/best_model.pkl** dan **preprocessing.pkl**; hasil ini selanjutnya diinterpretasikan lebih lanjut pada **03_interpretation.ipynb**. Seluruh logika inti seperti pemuatan data, pembagian data, pembangunan preprocessor, feature engineering, dan evaluasi model diletakkan secara modular di dalam folder **src/** (**data_preprocessing.py** dan **utils.py**), sehingga dapat dipakai ulang baik oleh notebook maupun oleh script CLI (**train_model.py** dan **evaluate_model.py**) tanpa duplikasi kode. Pada lapisan aplikasi, **app/app.py** memuat model terbaik satu kali menggunakan cache Streamlit agar efisien, kemudian menerima input nasabah dari form di sidebar, mengubahnya menjadi satu baris data, dan menerapkan fungsi **feature_engineering()** yang persis sama dengan yang digunakan saat training sebelum data tersebut diproses oleh model untuk menghasilkan prediksi label (Good/Bad) beserta probabilitas risikonya. Dengan digunakannya fungsi preprocessing dan feature engineering yang sama antara proses training dan proses inferensi, arsitektur ini menjamin konsistensi hasil prediksi dan meminimalkan risiko perbedaan perlakuan data antara tahap pelatihan model dan tahap penggunaan aplikasi oleh pengguna akhir.

Link Aplikasi Streamlit (Deployed) : <https://pm-4404-79qbb6hpg7qfiprh7kj7mk.streamlit.app/>

4.2 Fitur Utama Aplikasi

1). Dashboard EDA & Model Demo :

- **Sidebar Input Data Nasabah:** Menyediakan kontrol interaktif berupa *slider* (Age, Duration), *numeric input* (Credit amount), dan *selectbox* (Sex, Job, Housing, Saving accounts, Checking account, Purpose).
- **Tombol "Prediksi Risiko Kredit":** Tombol aksi berwarna merah untuk memproses input secara *real-time* menggunakan model *machine learning* terbaik.

2) Tampilan Probabilitas Per Kelas :

- **Tabel Ringkasan Input:** Menampilkan kembali seluruh data yang dimasukkan pengguna dalam bentuk tabular untuk verifikasi sebelum prediksi.
- **Metrik Probabilitas Risiko Bad:** Menampilkan hasil berupa kotak keputusan hijau (misal: *Hasil Prediksi: Good (layak)*) beserta persentase keyakinan model secara spesifik (misal: 48.3%).

3) Evaluasi Model : Halaman terpisah yang merujuk langsung pada performa model hasil eksekusi skrip **src/evaluate_model.py**.

4) Dokumentasi dan Keterbatasan Sistem : Memuat *disclaimer* teknis mengenai batasan model dan sumber data (*German Credit Data*) di bagian bawah halaman.

4.2.1 User Interface

The screenshot displays the 'Credit Risk Predictor' application. On the left, a sidebar titled 'Data Nasabah' contains input fields for Age (30), Sex (male), Job (3 - highly skilled), Housing (rent), Saving accounts (rich), Checking account (rich), Credit amount (23000), Duration (months) (24), and Purpose (furniture/equipment). The main area features the title 'Credit Risk Predictor' and a description. Below this, a 'Ringkasan Input' table lists the input values. A red button labeled 'Prediksi Risiko Kredit' is present. The prediction result is shown as 'Hasil Prediksi: Good (layak)' in a green box. Below this, the 'Probabilitas Risiko Bad' is displayed as 48.3%.

Age	Sex	Job	Housing	Saving accounts	Checking account	Credit amount	Duration	Purp	
0	30	male	3	rent	rich	rich	2300	24	fumi

Gambar 14. Hasil tangkapan layer aplikasi Streamlit Credit Risk Predictor jika GOOD (layak kredit)

The screenshot displays the 'Credit Risk Predictor' application with different input values. The sidebar shows Age (25), Sex (female), Job (3 - highly skilled), Housing (free), Credit amount (1000), Duration (months) (15), and Purpose (education). The 'Ringkasan Input' table reflects these changes. The prediction result is shown as 'Hasil Prediksi: Bad (tidak layak)' in a red box. Below this, the 'Probabilitas Risiko Bad' is displayed as 66.8%.

Age	Sex	Job	Housing	Saving accounts	Checking account	Credit amount	Duration	Purp	
0	25	female	3	free	quite rich	moderate	1000	15	educ

Gambar 15. Hasil tangkapan layer aplikasi Streamlit Credit Risk Predictor jika BAD (tidak layak kredit)

4.3 Validasi Input

Validasi input pada aplikasi prediksi risiko kredit dilakukan untuk memastikan data yang dimasukkan pengguna memiliki format dan nilai yang sesuai sebelum diproses oleh model machine learning. Validasi ini bertujuan untuk mengurangi kesalahan input serta memastikan data yang diterima oleh model memiliki struktur yang sama dengan data saat proses training. Validasi yang diterapkan meliputi:

- **Age (Usia)** dibatasi pada rentang 19 hingga 75 tahun.
- **Credit Amount (Jumlah Kredit)** memiliki nilai minimum 100 dan maksimum 20.000 (jika diinputkan lebih maka akan muncul pesan bahwa melebihi batas yang sudah ditentukan).
- **Duration (Durasi Kredit)** dibatasi antara 4 hingga 72 bulan. Validasi data kategorikal

- Pengguna hanya dapat memilih kategori yang tersedia pada dataset, seperti jenis kelamin, tempat tinggal, tabungan, rekening, dan tujuan kredit.

Validasi format data dilakukan dengan memastikan input yang diberikan pengguna memiliki struktur dan atribut yang sesuai dengan data training, yaitu **Age, Sex, Job, Housing, Saving accounts, Checking account, Credit amount, Duration, dan Purpose**. Sebelum proses prediksi dilakukan, sistem juga melakukan validasi ketersediaan model dengan mengecek keberadaan file **best_model.pkl** agar model dapat digunakan dengan benar. Setelah proses prediksi selesai, hasil prediksi akan divalidasi dan ditampilkan dalam bentuk kategori **Good (layak kredit)** atau **Bad (tidak layak kredit)** beserta nilai probabilitas risiko sebagai informasi tambahan. Dengan adanya validasi input tersebut, aplikasi dapat memastikan bahwa data yang masuk memiliki kualitas yang sesuai sehingga proses prediksi risiko kredit dapat berjalan secara akurat dan stabil.

4.4 Cara Menjalankan Aplikasi

Aplikasi ini menggunakan beberapa library utama, yaitu **Streamlit, Pandas, NumPy, Scikit-learn**, dan **Joblib**. Cara menjalankannya cukup mudah yaitu :

1. Instalasi library : `pip install streamlit pandas numpy scikit-learn joblib/ pip install -r requirements.txt`
2. Setelah seluruh library berhasil terinstal, pastikan struktur folder project sudah sesuai dengan kebutuhan aplikasi, yaitu terdapat folder **app** yang berisi file `app.py`, folder **models** yang berisi model terbaik `best_model.pkl`, serta folder **src** yang berisi fungsi preprocessing dan feature engineering.
3. Aplikasi dijalankan melalui terminal (CMD) pada folder utama project : `streamlit run app/app.py`
4. Streamlit akan menjalankan server lokal dan memberikan alamat aplikasi pada <http://localhost:8501>

BAB V

STRUKTUR REPOSITORY DAN DOKUMENTASI

5.1 Deskripsi DATASET

Seluruh kode, data, model, dan dokumentasi proyek disusun dalam repository dengan struktur berikut, mengikuti template yang sudah ditetapkan:

1. data/raw/ — data mentah (german_credit_data_updated.csv)
2. data/processed/ — data hasil preprocessing (dibuat otomatis oleh 02_modeling.ipynb, mis. data train/val/test setelah split)
3. data/external/ — data referensi eksternal (belum digunakan pada iterasi ini)
4. notebooks/01_eda.ipynb, 02_modeling.ipynb, 03_interpretation.ipynb — notebook EDA & data quality check, feature engineering–preprocessing–training–tuning, serta interpretasi (feature importance/SHAP) dan evaluasi akhir di test set
5. src/data_preprocessing.py, train_model.py, evaluate_model.py, utils.py — script modular untuk reproduksi pipeline (load & split data, build preprocessor, feature engineering, training, dan evaluasi via CLI)
6. models/best_model.pkl, preprocessing.pkl — model terbaik dan pipeline preprocessing tersimpan
7. app/app.py, app/pages/, app/assets/ — aplikasi Streamlit (Credit Risk Predictor) beserta halaman tambahan dan aset pendukung
8. reports/ — laporan akhir (final_report.pdf) dan slide presentasi (presentation.pptx)
9. requirements.txt, README.md, .gitignore — dependencies, dokumentasi, dan konfigurasi repository

README.md pada root repository berisi penjelasan struktur folder, alur kerja pipeline dari data mentah hingga aplikasi, panduan menjalankan proyek tahap demi tahap (setup, penyiapan data, eksekusi notebook, hingga menjalankan Streamlit), ringkasan lima insight EDA, serta ringkasan metodologi (split 70/15/15 stratified, feature engineering, strategi penanganan missing value bermakna, algoritma yang dibandingkan, dan dasar pemilihan model terbaik) menjadikannya dokumentasi utama proyek yang informatif dan mudah diikuti.

- **SC App.py :**
- https://drive.google.com/file/d/11jhBfQ4XRe-0tqZZtgQcx2L6LEW1Zpko/view?usp=drive_link
- **Link Deployment apk Streamlit :** <https://pm-4404-79qbb6hpg7qfiprh7kj7mk.streamlit.app/>
- **Link Youtube :** <https://youtu.be/9FjTqHnijM0?si=ToEy9vozztqunUvq>
- **Link Repo GITHUB :** <https://github.com/izza1234567859/PM-4404.git>

BAB VI

KESIMPULAN DAN REKOMENDASI

6.1 Kesimpulan

Berdasarkan hasil penelitian mengenai prediksi kelayakan kredit nasabah menggunakan algoritma machine learning pada dataset German Credit Data with Credit Risk, dapat disimpulkan bahwa:

1. Penelitian berhasil mengembangkan sistem prediksi kelayakan kredit mulai dari proses pengumpulan data, Exploratory Data Analysis (EDA), preprocessing, feature engineering, pelatihan model, evaluasi, hingga implementasi model ke dalam aplikasi berbasis Streamlit. Tahapan tersebut dilakukan secara sistematis untuk menghasilkan model yang dapat digunakan sebagai sistem pendukung keputusan dalam analisis kredit.
2. Hasil EDA menunjukkan bahwa faktor-faktor seperti jumlah kredit (Credit Amount), durasi kredit (Duration), serta kondisi rekening tabungan (Saving Accounts) dan rekening giro (Checking Account) memiliki hubungan yang cukup kuat terhadap tingkat risiko kredit. Nasabah dengan jumlah pinjaman lebih besar, durasi pinjaman lebih lama, dan kondisi rekening yang kurang baik cenderung memiliki risiko kredit yang lebih tinggi.
3. Tiga algoritma machine learning, yaitu Logistic Regression, Random Forest, dan XGBoost, berhasil diterapkan dan dibandingkan performanya. Berdasarkan hasil evaluasi pada validation maupun test set, Random Forest dipilih sebagai model terbaik karena memiliki keseimbangan performa yang paling baik, dengan nilai Accuracy sebesar 76,92%, ROC-AUC sebesar 0,8372 pada validation set, serta Recall kelas Bad sebesar 70,45% pada test set, sehingga memenuhi target utama penelitian dalam mendeteksi nasabah berisiko tinggi.

6.2 Rekomendasi

Beberapa rekomendasi yang dapat dilakukan untuk pengembangan penelitian selanjutnya adalah sebagai berikut.

1. Menggunakan dataset yang lebih besar, lebih beragam, dan lebih representatif terhadap kondisi kredit di Indonesia agar model memiliki kemampuan generalisasi yang lebih baik.
2. Menambahkan variabel atau fitur lain yang berpotensi memengaruhi risiko kredit, seperti pendapatan, riwayat pembayaran, rasio utang, status pekerjaan, maupun skor kredit sehingga model dapat menghasilkan prediksi yang lebih akurat.
3. Mencoba algoritma machine learning lain seperti LightGBM, CatBoost, maupun teknik ensemble yang lebih kompleks untuk memperoleh performa klasifikasi yang lebih baik.
4. Melakukan optimasi hyperparameter yang lebih mendalam menggunakan teknik seperti Bayesian Optimization atau Optuna agar performa model dapat ditingkatkan dibandingkan metode tuning konvensional.

REFERENSI

- (Teary 2025)Chen, Tianqi, and Carlos Guestrin. 2016. "XGBoost : A Scalable Tree Boosting System." : 785–94.
- Credit, A New, Scoring Model, For Vehicle, and Leasing Company. 2022. "Jurnal Pendidikan Dan Konseling." 4: 5752–59.
- Pebradi, Muhammad Syahid. 2026. "Machine Learning-Based Credit Risk Classification Using German Credit Data." (1): 122–26.
- Prahastiwi, Narita Ayu, Muharman Lubis, Hanif Fakhurroja, Article Info, Credit Scoring, Ensemble Supervised Learning, and Non Performing Loan. 2025. "The Ensemble Supervised Machine Learning for Credit Scoring Model in Digital Banking Institution." 8(2): 466–77.
- Teary, Muhammad Gald. 2025. "OPTIMALISASI MODEL CREDIT SCORING MENGGUNAKAN ALGORITMA LOGISTIC REGRESSION DAN DECISION TREE." 16(03): 352–58.